

AI Skills

Експерт. Інтеграція API ШІ в проєкті

План

- Що таке API LLM?
- Які основні способи взаємодії з API LLM?
- Як використовувати API LLM?
- Які задачі ШІ API може вирішувати?
- Що таке TensorFlow.js / ONNX Runtime / ml5.js?
- Чим відрізняється JS-ML від LLM?
- Як використовувати LLM локально і як викликати локальну LLM з JS?
- Online vs Offline: переваги й недоліки.
- Що таке токен в контексті ШІ?

Вступ. Як фронтенд-розробники можуть використовувати ШІ вже сьогодні

AI Skills

Що таке API LLM?

API LLM — це програмний інтерфейс (API), через який ти можеш інтегрувати можливості LLM у свої додатки, сервіси або бізнес-процеси. Іншими словами — це набір інструментів і протоколів для віддаленого звернення до LLM через інтернет. Простіше кажучи: API LLM дозволяє твоєму коду "розмовляти" з великим мовним ШІ через HTTP-запити.

Як працює API LLM?

- Ти відправляєш запит (HTTP POST) на API, де в тілі передаєш текстову інструкцію (наприклад: "Напиши резюме статті", або "Переклади текст на англійську").
- LLM обробляє запит, аналізує його і генерує відповідь.
- Ти отримуєш результат у вигляді тексту (JSON-відповідь).

Вступ. Як фронтенд-розробники можуть використовувати ШІ вже сьогодні

Які основні способи взаємодії з API LLM?

Спосіб	Опис	Приклади
1. REST API (HTTP-запити)	Стандартний підхід через POST-запити. Використовується через будь-яку мову програмування.	C#, Python, JavaScript, curl
2. SDK / Офіційні бібліотеки	Готові клієнтські бібліотеки для .NET, Python, Node.js та інших. Спрощують роботу з API.	OpenAI .NET SDK, OpenAI Python SDK
3. gRPC API	Деякі провайдери пропонують gRPC API для швидших запитів з меншою затримкою.	(рідше, але зустрічається у корпоративних рішеннях)
4. WebSocket Streaming API	Для сценаріїв, де потрібен стрімінговий відгук токен за токеном (наприклад, живе відображення відповіді).	OpenAI Streaming API
5. CLI інструменти (Command-line tools)	Інструменти типу openai CLI або curl, які дозволяють викликати LLM API прямо з терміналу.	OpenAI CLI
6. No-code / Low-code інтеграції	Інтеграція через платформи на кшталт Zapier, Make (Integromat), Power Automate.	Використовується нетехнічними користувачами
7. Хмарні функції (Azure Functions, AWS Lambda)	Виклик LLM API в рамках serverless-функцій.	Автоматизація процесів
8. Вбудовані інтеграції у SaaS сервіси	API LLM можуть бути вбудовані безпосередньо у сервіси типу Notion, Slack, Google Docs.	Вбудований AI

Вступ. Як фронтенд-розробники можуть використовувати ШІ вже сьогодні

AI Skills

Як використовувати API LLM?

REST запит:

```
POST https://api.openai.com/v1/chat/completions
Authorization: Bearer YOUR_API_KEY
Content-Type: application/json

{
  "model": "gpt-4o",
  "messages": [
    {"role": "user", "content": "Поясни що таке API LLM"}
  ],
  "temperature": 0.7
}
```

Відповідь у форматі JSON:

```
{
  "choices": [
    {
      "message": {
        "role": "assistant",
        "content": "API LLM - це..."
      }
    }
  ]
}
```

Вступ. Як фронтенд-розробники можуть використовувати ШІ вже сьогодні

AI Skills

Які задачі ШІ API може вирішувати?

- Генерація тексту (статті, листи, маркетингові описи)
- Переклад текстів
- Підсумовування великих обсягів тексту
- Класифікація і категоризація тексту
- Відповіді на питання (Q&A)
- Аналіз настрою
- Чат-боти і віртуальні асистенти
- Автоматизація обробки заявок / email-розсилок
- Генерація коду або SQL-запитів
- Обробка звуку
- Обробка зображень
- Обробка відео

Вступ. Як фронтенд-розробники можуть використовувати ШІ вже сьогодні

AI Skills

Що таке TensorFlow.js, ONNX Runtime, ml5.js ?

TensorFlow.js — бібліотека для тренування і запуску моделей прямо в браузері або Node.js. Підтримує створення, тренування та inference.

ONNX Runtime Web — дозволяє запускати моделі у форматі ONNX у браузері (WebAssembly, WebGPU) або в Node.js.

ml5.js — високорівневий wrapper над TensorFlow.js, орієнтований на простоту: готові моделі (позначення, стиль, класифікація) для швидких прототипів.

Що можна робити?

- Класифікація зображень, виявлення об'єктів (з готовими моделями)
- Аналіз тексту (word embeddings, прості класифікатори)
- Прогнозування на основі табличних даних (регресія)
- Запуск невеликих нейромереж в браузері для швидких demo

Вступ. Як фронтенд-розробники можуть використовувати ШІ вже сьогодні

AI Skills

Яка різниця між ML та LLM?

ML та LLM (Large Language Models) — це різні підходи в машинному навчанні, з різними цілями, масштабами і сценаріями використання.

- **ML (TF.js / ONNX):** ти тренуєш чи використовуєш невеликі локальні моделі, контроль над даними, підходить для специфічних задач (регресія, класифікація).
- **LLM:** сильні в роботі з природною мовою, великі, часто через API, не завжди можна запускати локально без потужного заліза.

Вступ. Як фронтенд-розробники можуть використовувати ШІ вже сьогодні

AI Skills

Як можна використати LLM локально?

Це значить, що модель запускається на вашому комп'ютері або сервері, а не через API (як OpenAI, Azure тощо). Ви не відправляєте дані в інтернет — все працює офлайн.

Як запускати LLM локально?

- Через **Ollama** (найпростіший спосіб). Ollama — це CLI/додаток, який дозволяє легко запускати LLM у вашій системі.
- Через **LM Studio** (GUI). Безкоштовний GUI-додаток для запуску LLM
- Через **ONNX / GGUF / PyTorch** (низькорівневий підхід). Це модель у форматі ONNX (для C# через ONNX Runtime)

Вступ. Як фронтенд-розробники можуть використовувати ШІ вже сьогодні

AI Skills

Які переваги та недоліки використання онлайн та оффлайн API LLM?

Онлайн

+

- Доступ до найпотужніших моделей
- Мінімальний час на запуск
- Автоматичне оновлення моделей
- Масштабованість
- Інтеграція через SDK
- Доступ до просунутих фіч (Tool Use, Function Calling, RAG)

-

- Ціна
- Залежність від інтернету
- Конфіденційність і безпека
- Обмеження API (rate limits, max tokens)
- Затримки через мережу

Оффлайн

+

- Повна приватність
- Безкоштовне використання (після завантаження моделі)
- Працює без інтернету
- Гнучкість
- Можеш кастомізувати / fine-tune

-

- Вимоги до заліза (RAM, VRAM)
- Якість гірша за GPT-5 / Gemini Pro
- Немає деяких можливостей (наприклад Function Calling)
- Треба налаштовувати середовище
- Відсутність офіційних SDK для .NET

Вступ. Як фронтенд-розробники можуть використовувати ШІ вже сьогодні

AI Skills

Що таке токен в контексті ШІ?

Текст	Токени
Hello, world!	Hello, ,, world, !
Привіт, світе!	Прив, іт, ,, св, іте, !
int count = 5;	int, count, =, 5, ;

Токен — це одиниця тексту, яку модель обробляє при генерації або аналізі тексту. Токен $\neq$ слово і токен $\neq$ символ. Токен може бути частиною слова, цілим словом або навіть знаком пунктуації.

На що впливає велике споживання токенів?

- Ціна. Ви платите за кожні 1000 токенів (Open AI)
- Обмеження запиту. GPT-4o має ліміт $\sim 128k$ токенів на весь контекст
- Час генерації. Чим більше токенів — тим довше відповідь
- Пам'ять. Більше токенів - більше споживання пам'яті

Для української мови:

Зазвичай кількість токенів на 20-30% більша, ніж кількість слів, бо українські слова часто довші і розбиваються на кілька токенів.

Навчальний центр інформаційних технологій

CyberBionic
s y s t e m a t i c s

